Computação Aplicada à Economia: Tópicos em Aprendizado de Máquina

Kauê Lopes de Moraes

Setembro 2026

1 Contexto e Justificativa

A crescente disponibilidade de dados econômicos, financeiros e administrativos ampliou as possibilidades de investigação empírica e de apoio à tomada de decisão. Ao mesmo tempo, o aumento do volume e da complexidade dessas informações tornou insuficiente a realização de análises baseadas exclusivamente em procedimentos manuais ou em ferramentas pouco reprodutíveis. Nesse contexto, métodos computacionais e técnicas de aprendizado de máquina passaram a ocupar um espaço importante na pesquisa econômica e na atuação profissional de economistas.

O aprendizado de máquina oferece instrumentos para identificar padrões, realizar previsões e construir modelos capazes de generalizar relações observadas nos dados. Entretanto, sua aplicação responsável exige mais do que o domínio de bibliotecas computacionais: é necessário compreender como os modelos aprendem, como seu desempenho deve ser avaliado e quais são os limites de interpretação de seus resultados. Questões como sobreajuste, escolha de métricas, separação de amostras e validação são fundamentais para evitar conclusões frágeis ou excessivamente otimistas.

Este curso propõe uma introdução aplicada a esses temas, combinando intuição econômica, fundamentos estatísticos e implementação computacional em Python. Partindo dos fundamentos da linguagem e da computação numérica com NumPy e JAX, a proposta é capacitar os participantes a compreender a lógica dos principais procedimentos de aprendizado supervisionado, implementar um modelo de regressão linear por gradiente descendente, explorar árvores aleatórias e redes neurais como aproximadores

de funções e analisar aplicações contemporâneas em pesquisa econômica de maneira crítica, reproduzível e orientada por problemas reais.

2 Recomendações

Não é necessário conhecimento prévio de programação, pois a primeira aula apresenta os fundamentos de Python e das bibliotecas de computação numérica utilizadas ao longo do curso. Os materiais abaixo são sugestões de estudo complementar e estão organizados de acordo com o nível de familiaridade do participante.

Recomendações para Iniciantes

- DOWNEY, Allen B. *Pense em Python: Pense como um Cientista da Computação.*
- **3Blue1Brown — Neural Networks:** `https://www.3blue1brown.com/?topic=neural-networks`
- **Kaggle Learn — Intro to Machine Learning:** `https://www.kaggle.com/learn/intro-to-machine-learning`
- **Kaggle Learn — Intermediate Machine Learning:** `https://www.kaggle.com/learn/intermediate-machine-learning`

Recomendações para Intermediários

- CORMEN, Thomas H. et al. *Algoritmos: Teoria e Prática.*
- **Kaggle Learn — Intro to Deep Learning:** `https://www.kaggle.com/learn/intro-to-deep-learning`
- GÉRON, Aurélien. *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow.*

3 Objetivos do Curso

Ao final do curso, o participante estará apto a escrever programas básicos em Python; manipular vetores e matrizes com NumPy e JAX; compreender

os fundamentos do aprendizado de máquina e sua relação com a estatística e a econometria; distinguir problemas de previsão e de inferência; preparar dados para treinamento, teste e validação; reconhecer situações de sobreajuste e subajuste; interpretar métricas de desempenho; implementar uma regressão linear por gradiente descendente; compreender árvores aleatórias e redes neurais como aproximadores de funções não lineares; e avaliar aplicações de aprendizado de máquina em pesquisa econômica.

O foco central é fornecer uma base conceitual e computacional que permita ao participante utilizar essas ferramentas de forma criteriosa, transparente e reproduzível, entendendo não apenas como executar um algoritmo, mas também por que ele funciona, em quais situações pode ser útil e quais cuidados devem orientar a interpretação dos resultados.

4 Competências Desenvolvidas

O curso desenvolve competências relacionadas à programação básica em Python, à computação vetorizada com NumPy e JAX, à formulação de problemas econômicos como tarefas de aprendizado de máquina, à organização de fluxos reproduzíveis de análise e à avaliação crítica da capacidade preditiva de modelos. O participante aprenderá a diferenciar ajuste dentro da amostra e generalização fora da amostra, selecionar estratégias adequadas de validação e interpretar o papel da função de perda no processo de treinamento.

Além disso, o curso fortalecerá a compreensão da regressão linear sob uma perspectiva computacional, conectando conceitos familiares da econometria ao funcionamento do gradiente descendente. O participante também compreenderá como árvores aleatórias e redes neurais representam relações não lineares e como a complexidade desses modelos afeta sua capacidade de generalização. Por meio da discussão de casos de pesquisa, será capaz de identificar oportunidades, limitações e riscos associados ao uso de aprendizado de máquina em problemas econômicos concretos.

5 Estrutura Programática e Cronograma (12h)

O curso está estruturado em 6 aulas de 2 horas, equilibrando fundamentação conceitual, implementação computacional e discussão de aplicações em Economia. Todas as aulas incluem atividades práticas desenvolvidas principal-

mente no ambiente Google Colab. Ao final de cada encontro, serão disponibilizados materiais complementares para os participantes que desejarem aprofundar os conceitos, métodos e aplicações apresentados.

Aula 1: Introdução a Python, NumPy e JAX

- **Conteúdo:** Configuração do ambiente de trabalho; uso do Jupyter Notebook; variáveis, tipos de dados, operadores, funções, estruturas condicionais e estruturas de repetição em Python; introdução a vetores, matrizes e operações vetorizadas com NumPy; apresentação do JAX; diferenciação automática; compilação e operações com arrays.

- **Aplicação:** Construção de pequenos programas para manipular dados econômicos, realizar cálculos matriciais e comparar uma implementação baseada em laços com uma solução vetorizada. Introdução ao cálculo automático de derivadas de funções simples com JAX.

- **Justificativa:** Estabelecer a base computacional necessária para as aulas seguintes e permitir que participantes sem experiência prévia em programação compreendam a representação dos dados, as operações matriciais e os mecanismos de diferenciação utilizados no treinamento de modelos.

Aula 2: O que é Aprendizado de Máquina?

- **Conteúdo:** Definição e objetivos do aprendizado de máquina; relações e diferenças entre estatística, econometria e aprendizado de máquina; aprendizado supervisionado e não supervisionado; variáveis explicativas, variável-alvo e observações; problemas de regressão e classificação; previsão e inferência; introdução ao fluxo de trabalho de um projeto em Python.

- **Aplicação:** Formulação de problemas econômicos como tarefas preditivas, utilizando exemplos como previsão de preços, classificação de risco de crédito e identificação de grupos com padrões semelhantes de consumo.

- **Justificativa:** Construir uma linguagem comum e uma base conceitual que permitam compreender o que significa um algoritmo aprender a

partir de dados, evitando que o aprendizado de máquina seja tratado apenas como um conjunto de comandos prontos.

Aula 3: Treino, Teste e Validação: Aprendendo ou Decorando?

- **Conteúdo:** Generalização fora da amostra; divisão entre conjuntos de treino, validação e teste; sobreajuste e subajuste; compromisso entre viés e variância; validação cruzada; escolha de hiperparâmetros; vazamento de dados; métricas para regressão e classificação; cuidados específicos com dados temporais.

- **Aplicação:** Comparação do desempenho de modelos com diferentes níveis de complexidade e construção de um procedimento de avaliação que preserve a integridade do conjunto de teste.

- **Justificativa:** Demonstrar que um bom ajuste aos dados conhecidos não garante capacidade preditiva. A aula enfatiza procedimentos que permitem verificar se o modelo aprendeu relações generalizáveis ou apenas memorizou particularidades da amostra.

Aula 4: Regressão Linear por Gradiente Descendente

- **Conteúdo:** Revisão da regressão linear; representação matricial do modelo; função de perda pelo erro quadrático médio; interpretação geométrica do gradiente; derivação das regras de atualização; taxa de aprendizado, convergência e critérios de parada; padronização das variáveis; implementação do algoritmo em Python; comparação com a solução por mínimos quadrados ordinários.

- **Aplicação:** Implementação passo a passo de uma regressão linear sem utilizar um estimador pronto, com visualização da trajetória da função de perda e análise da influência da taxa de aprendizado.

- **Justificativa:** Tornar concreto o processo de treinamento de um modelo. Ao implementar o gradiente descendente, o participante conecta fundamentos de econometria, cálculo e programação, compreendendo a lógica utilizada em modelos de maior complexidade.

Aula 5: Árvores Aleatórias e Redes Neurais: Aproximadores de Funções

- **Conteúdo:** Relações lineares e não lineares; árvores de decisão para regressão e classificação; critérios de divisão e profundidade; sobreajuste em árvores; combinação de modelos; amostragem bootstrap e seleção aleatória de variáveis; árvores e florestas aleatórias; estrutura de uma rede neural; camadas, pesos, vieses e funções de ativação; redes neurais como composições de funções; treinamento por retropropagação e gradiente descendente.

- **Aplicação:** Ajuste de árvores aleatórias e redes neurais a uma função econômica não linear, com comparação das previsões, da flexibilidade, do erro fora da amostra e da sensibilidade dos modelos às escolhas de hiperparâmetros.

- **Justificativa:** Ampliar a discussão para modelos capazes de representar relações complexas sem impor previamente uma forma funcional rígida. A comparação entre árvores aleatórias e redes neurais permite compreender duas estratégias distintas de aproximação de funções e relacioná-las aos conceitos de treinamento, regularização e generalização apresentados nas aulas anteriores.

Aula 6: Casos de Aprendizado de Máquina em Pesquisa Econômica

- **Conteúdo:** Aplicações em previsão macroeconômica, mercado de trabalho, risco de crédito, avaliação de políticas públicas, classificação de textos e uso de dados alternativos; diferenças entre desempenho preditivo e identificação causal; interpretabilidade; importância das variáveis; qualidade, representatividade e documentação dos dados; vieses algorítmicos; reprodutibilidade e comunicação de resultados.

- **Aplicação:** Leitura orientada e reprodução simplificada de estudos de caso com bases econômicas, seguida da discussão sobre a escolha do modelo, a estratégia de validação e os limites das conclusões obtidas.

- **Justificativa:** Consolidar os conceitos das aulas anteriores por meio de aplicações reais e desenvolver uma postura crítica diante do uso de

algoritmos em pesquisa econômica, distinguindo ganhos de previsão de evidências causais ou explicações estruturais.

6 Metodologia

A metodologia proposta baseia-se no aprendizado ativo (*active learning*), articulando intuição econômica, formalização matemática e implementação computacional. A carga horária é distribuída em uma proporção aproximada de 40% de fundamentação teórica e 60% de aplicação prática guiada.

A estratégia pedagógica divide-se em três pilares fundamentais:

1. **Conexão entre Economia e Computação:** Os conceitos de aprendizado de máquina são apresentados a partir de conhecimentos familiares aos participantes, como regressão, previsão, erro de estimação e análise fora da amostra. Essa conexão permite compreender continuidades e diferenças entre a abordagem econométrica tradicional e os métodos computacionais de aprendizagem.

2. **Aprendizado pela Implementação:** Todas as aulas combinam exposição e prática computacional. Os participantes acompanham a construção dos procedimentos em Python e investigam como alterações nos dados, nos hiperparâmetros e na especificação do modelo afetam os resultados. A implementação do gradiente descendente ocupa papel central, pois revela os mecanismos que normalmente ficam ocultos em funções prontas.

3. **Resolução de Casos Econômicos Reais:** As atividades utilizam dados relacionados a preços, atividade econômica, mercado de trabalho, crédito e políticas públicas. Cada caso é tratado como um problema de pesquisa, incluindo a definição da pergunta, a preparação dos dados, a escolha do método, a validação e a comunicação responsável dos resultados.

Dinâmica das Aulas

As sessões de 2 horas seguem o fluxo:

- **Motivação e Fundamentação Teórica (1h):** Apresentação de uma questão econômica ou de pesquisa que orientará a aula, seguida do desenvolvimento da intuição estatística, econômica e matemática necessária para compreender o método.
- **Demonstração Computacional (30 min):** Construção e explicação do código pelo instrutor (*Live Coding*) no Google Colab.
- **Laboratório Assistido (30 min):** Aplicação prática dos conceitos pelos participantes no Google Colab, com experimentação, comparação de resultados e resolução de extensões do problema original.

O ambiente de desenvolvimento utilizado prioritariamente será o **Google Colab**, que permite executar notebooks diretamente pelo navegador e integrar código, equações, visualizações e documentação narrativa sem exigir uma configuração local complexa. Essa organização favorece a participação nas atividades práticas, a transparência das decisões analíticas e a reprodução dos resultados. Em todas as aulas, os participantes receberão indicações de leituras, notebooks, exercícios ou referências adicionais para aprofundamento voluntário após o encontro.